

BAM Hizalama Kalite Kontrolü ve Temel İstatistiklerin Değerlendirilmesi

1. Amaç ve Giriş

Yeni nesil dizileme çalışmalarında ham dizileme verileri çoğunlukla FASTQ formatında elde edilir ve daha sonra bir referans genoma hizalanır. Hizalama sonucunda oluşan SAM/BAM dosyaları, yalnızca DNA dizilerini değil, her okumanın referans genom üzerinde hangi konuma yerleştirildiğini, hizalamanın güven düzeyini, eşli okuma bilgisini ve çeşitli kalite ölçütlerini de içerir.

SAM (Sequence Alignment/Map) metin tabanlı bir hizalama formatıdır. BAM ise aynı bilgilerin sıkıştırılmış binary biçimidir. BAM formatının daha az disk alanı kullanması ve indekslenerek genomun belirli bölgelerine hızlı erişim sağlaması, büyük genomik veri setlerinde yaygın olarak kullanılmasını sağlamaktadır.

Bu çalışmanın amacı, Broad Institute GATK test verileri arasında bulunan CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam dosyasının hizalama sonrası kalite kontrolünü gerçekleştirmektir. Analizde toplam okuma sayısı, hizalanma oranı, mapping quality (MAPQ) dağılımı, paired-end yapısı, insert size dağılımı ve kapsama derinliği değerlendirilmiştir. Ayrıca düşük MAPQ değerlerinin genom boyunca rastgele dağılıp dağılmadığı incelenerek, düşük hizalama güveninin olası kaynağı araştırılmıştır.

Çalışmada temel analiz aracı olarak Picard Tools 3.5.0 kullanılmış, MAPQ dağılımı ise BAM dosyasının SAM formatına dönüştürülmesinin ardından PowerShell ile hesaplanmıştır.

2. Veri Seti ve Yazılım Ortamı

Analiz edilen dosya:

CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam

BAM başlığı incelendiğinde dosyanın coordinate-sorted olduğu ve yalnızca kromozom 20 ve 21 için referans kayıtları içerdiği görülmüştür. Referans uzunlukları kromozom 20 için 63,025,520 bp, kromozom 21 için 48,129,895 bp olarak belirlenmiştir.

Read group bilgilerinde örnek adı NA12878, sequencing platformu ise Illumina olarak belirtilmiştir. İki farklı kütüphane (Solexa-18483 ve Solexa-18484) bulunmaktadır. BAM başlığındaki @PG kayıtları hizalamanın BWA 0.5.9-r16 ile gerçekleştirildiğini, daha sonra

GATK 1.2 kullanılarak IndelRealigner ve TableRecalibration adımlarının uygulandığını göstermektedir.

Analiz ortamı Windows 11 üzerinde OpenJDK 17.0.20.1 ve Picard Tools 3.5.0 kullanılarak oluşturulmuştur.

BAM dosyasındaki gerçek hizalanma koordinatları ayrıca incelendiğinde, verinin kromozomların tamamını değil yalnızca sınırlı test bölgelerini içerdiği görülmüştür. Kromozom 20’de hizalanmalar yaklaşık 9,999,902–10,250,000, kromozom 21’de ise 9,999,901–10,215,938 aralığında bulunmaktadır. Dolayısıyla bu veri seti tam kapsamlı bir WGS BAM dosyası olarak değil, WGS verisinden oluşturulmuş sınırlı bir test alt kümesi olarak değerlendirilmiştir.

3. Yöntem

3.1. BAM dosyasının yapısal doğrulanması

İlk olarak BAM dosyasının yapısal bütünlüğünü değerlendirmek amacıyla Picard ValidateSamFile aracı kullanılmıştır.

```
java -jar picard.jar ValidateSamFile ^
```

```
-I CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam ^
```

```
-MODE SUMMARY
```

Doğrulama sonucunda 16 adet INVALID_PLATFORM_VALUE ve 976 adet MATE_NOT_FOUND kaydı tespit edilmiştir. Platform hatasının BAM header içerisinde platform bilgisinin illumina şeklinde küçük harfle yazılmasından kaynaklandığı düşünülmektedir. Bu durum hizalama sonuçlarından çok metadata standardizasyonu ile ilişkilidir.

MATE_NOT_FOUND kayıtlarının ise verinin tam genom BAM dosyası yerine sınırlı bir test alt kümesi olmasından kaynaklanması olasıdır. Bir paired-end fragmentinin bir okuması seçilen bölgede bulunurken eş okumasının subset dışında kalması mümkündür. Bu nedenle bu kayıtlar doğrudan sequencing library hatası olarak yorumlanmamıştır.

3.2. Temel hizalama metrikleri

Toplam read sayısı ve temel hizalama ölçütleri Picard CollectAlignmentSummaryMetrics ile hesaplanmıştır.

```
java -jar picard.jar CollectAlignmentSummaryMetrics ^  
-I CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam ^  
-O alignment_metrics.txt ^  
-VALIDATION_STRINGENCY LENIENT
```

Picard çıktısında veri setinde toplam 654,610 read bulunduğu ve 583,884 read'in referansa hizalandığı belirlenmiştir. Ortalama read uzunluğu 101 bp olup tüm reads aynı uzunluktadır.

3.3. MAPQ dağılımının hesaplanması

MAPQ, bir read'in referans üzerinde atandığı konuma duyulan güveni ifade eder. Yüksek MAPQ değerleri daha güvenilir ve genellikle daha benzersiz hizalanmaları gösterirken, MAPQ=0 bir read'in birden fazla genomik konuma benzer kalitede hizalanabilmesi gibi önemli bir belirsizliğe işaret edebilir.

MAPQ analizi için BAM dosyası önce SAM formatına dönüştürülmüştür.

```
java -jar picard.jar SamFormatConverter ^  
-I CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam ^  
-O sample.sam ^  
-VALIDATION_STRINGENCY LENIENT
```

Daha sonra yalnızca primary ve mapped alignment kayıtları kullanılarak MAPQ değerleri PowerShell ile çıkarılmıştır. Unmapped, secondary ve supplementary kayıtlar analiz dışında tutulmuştur.

Bu işlem sonucunda MAPQ=0, MAPQ<20, MAPQ≥20 ve MAPQ≥30 gruplarının oranları hesaplanmıştır.

3.4. Insert size analizi

Paired-end sequencing library yapısını değerlendirmek amacıyla CollectInsertSizeMetrics kullanılmıştır.

```
java -jar picard.jar CollectInsertSizeMetrics ^  
-I CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam ^  
-O insert_size_metrics.txt ^  
-M 0.5 ^  
-VALIDATION_STRINGENCY LENIENT
```

Analiz duplicate olarak işaretlenmiş reads'i varsayılan olarak dışarıda bırakmıştır.

3.5. Coverage analizi

Coverage analizinde BAM ile uyumlu GRCh37/b37 referansı kullanılmıştır. Yalnızca kromozom 20 ve 21 dizilerini içeren bir referans FASTA hazırlanmış ve kromozom isimleri BAM header ile uyumlu olacak şekilde 20 ve 21 olarak düzenlenmiştir.

Picard CollectWgsMetrics kullanılarak yalnızca BAM'de gerçekten veri bulunan bölgeler değerlendirilmiştir. Böylece kromozomların veri bulunmayan milyonlarca bazlık kısımlarının coverage ortalamasını yapay olarak düşürmesi engellenmiştir.

Birleştirilmiş analiz için kullanılan bölgeler:

20:9,999,902-10,250,000

21:9,999,901-10,215,938

CollectWgsMetrics varsayılan olarak minimum MAPQ 20 ve minimum base quality 20 kullanmıştır. Dolayısıyla hesaplanan coverage değerleri ham read depth yerine kalite filtrelerinden geçen yüksek güvenli coverage'ı temsil etmektedir.

Kromozom 20 ve 21 ayrıca bağımsız olarak analiz edilerek bölgesel farklılıklar karşılaştırılmıştır.

4. Bulgular

4.1. Temel hizalama sonuçları

Temel alignment metrikleri Tablo 1’de özetlenmiştir.

Metrik	Sonuç
Toplam read	654,610
Primary mapped read	583,884
Mapping rate	89.20%
MAPQ = 0	287,952 / 49.32%
MAPQ <20	323,545 / 55.41%
MAPQ ≥20	260,339 / 44.59%
MAPQ ≥30	224,257 / 38.41%
Reads aligned in pairs	96.45%
Improper pairs	3.85%
Ortalama read uzunluğu	101 bp
Strand balance	0.4997
Soft-clipping oranı	5.09%

Picard analizinde toplam 654,610 read’ın 583,884’ünün hizalandığı ve mapping oranının yaklaşık %89.20 olduğu görülmüştür. Ayrıca reads’in %96.45’inin pair halinde hizalanması paired-end yapısının genel olarak korunduğunu göstermektedir. Ortalama read uzunluğu 101 bp ve strand balance yaklaşık 0.50’dir. Bu durum forward ve reverse strandlar arasında belirgin bir dengesizlik olmadığını göstermektedir.

4.2. MAPQ dağılımı

Primary mapped reads içerisinde MAPQ dağılımı dikkat çekici biçimde heterojen bulunmuştur. Toplam 583,884 mapped read'ın 287,952'si, yani %49.32'si MAPQ=0 değerine sahiptir.

MAPQ $\geq$ 20 read sayısı 260,339 (%44.59), MAPQ $\geq$ 30 read sayısı ise 224,257 (%38.41) olarak hesaplanmıştır.




Figure 1. MAPQ distribution of primary mapped reads. The distribution is strongly bimodal, with dominant peaks at MAPQ=0 (287,952 reads) and MAPQ=60 (207,297 reads).

Şekil 1. Primary mapped reads için MAPQ dağılımı. Dağılım MAPQ=0 ve yüksek MAPQ değerlerinde belirgin iki grup göstermektedir.

İlk bakışta yüksek MAPQ=0 oranı genel alignment kalitesinin düşük olduğu izlenimini oluşturabilir. Ancak MAPQ=0 reads'in genomik konumları ayrıca analiz edildiğinde çok farklı bir tablo ortaya çıkmıştır.

Kromozom 21'de 287,529 MAPQ=0 read bulunurken, kromozom 20'de yalnızca 423 MAPQ=0 read gözlenmiştir. Daha ayrıntılı bölgesel analiz, tüm MAPQ=0 reads'in yaklaşık %99.8'inin kromozom 21'in 10–11 Mb bininde yoğunlaştığını göstermiştir.

Aynı bölgelerin yüksek kaliteli reads açısından karşılaştırılması da bu sonucu desteklemiştir.

Bölge	MAPQ=0	MAPQ≥30
chr20:10–11 Mb bin	423	209,753
chr21:10–11 Mb bin	287,341	14,394

Kromozom 21’de MAPQ=0 reads’in MAPQ≥30 reads’e oranı yaklaşık 20:1 iken, kromozom 20’de yüksek kaliteli hizalanmalar açık biçimde baskındır.

Bu nedenle veri setindeki yüksek MAPQ=0 oranının genom genelinde yaygın bir sequencing veya alignment bozukluğunu değil, büyük ölçüde belirli bir chr21 bölgesindeki mapping ambiguity’yi temsil ettiği sonucuna varılmıştır.

4.3. Insert size sonuçları

Insert size analizinde median fragment uzunluğu 396 bp, mode 398 bp ve ortalama 391.59 bp olarak bulunmuştur. Standart sapma 41.92 bp, median absolute deviation ise 23 bp’dir. Analize 248,406 read pair dahil edilmiştir ve baskın pair orientation FR olarak belirlenmiştir.

Insert size metriği	Sonuç
Median insert size	396 bp
Mode insert size	398 bp
Mean insert size	391.59 bp
Standard deviation	41.92 bp
Median absolute deviation	23 bp
Read pairs	248,406
Pair orientation	FR

Mean, median ve mode değerlerinin birbirine oldukça yakın olması, ana insert-size dağılımının yaklaşık 400 bp civarında yoğunlaştığını göstermektedir. Histogram verilerinde en yoğun değerlerin yaklaşık 390–410 bp civarında bulunduğu görülmektedir. Örneğin 398 bp insert size değerinde 3,266 read pair bulunmuştur.

Maksimum insert size çok yüksek bir uç değer göstermesine rağmen ana dağılımın mean, median ve mode değerleri bundan belirgin şekilde etkilenmemiştir. Bu nedenle söz konusu maksimum değer az sayıdaki anomalous/chimeric pair nedeniyle oluşan bir outlier olduğu düşünülmektedir.




Figure 2. Insert-size distribution of paired-end reads. The distribution is centered near 400 bp (median 396 bp, mean 391.6 bp, mode 398 bp; SD 41.9 bp).

Şekil 2. Paired-end reads için insert-size dağılımı. Ana dağılım yaklaşık 400 bp çevresinde yoğunlaşmaktadır.

4.4. Birleştirilmiş coverage sonuçları

Seçilen chr20 ve chr21 bölgeleri birlikte değerlendirildiğinde Picard 416,137 bp GENOME_TERRITORY raporlamıştır. Mean high-quality coverage 50.35×, median coverage ise 62× bulunmuştur. Bölgenin %83.19'u en az 1×, %72.83'ü en az 10×, %68.72'si en az 20× ve %65.65'i en az 30× coverage'a sahiptir.

Dikkat çekici biçimde PCT_EXC_MAPQ değeri 0.553023'tür. Bu değer, coverage'a katkı sağlayabilecek bazların yaklaşık %55.3'ünün MAPQ filtresi nedeniyle dışlandığını göstermektedir. Bu oran bağımsız MAPQ analizinde hesaplanan %55.41 MAPQ<20 read oranıyla oldukça uyumludur.

Duplicate nedeniyle dışlanan oran yaklaşık %5.27, düşük base quality nedeniyle dışlanan oran ise yalnızca %0.86'dır. Bu nedenle coverage kaybının başlıca kaynağının sequencing base quality veya duplication değil, mapping confidence olduğu görülmektedir.

Coverage histogramında 69,958 bazın yüksek kaliteli coverage değerinin 0 olduğu görülmüştür. Buna karşılık coverage'ın önemli bir bölümü 60–90× aralığında yoğunlaşmaktadır.

4.5. Kromozom 20 ve 21'in karşılaştırılması

Kromozomlar bağımsız analiz edildiğinde çok belirgin bir fark ortaya çıkmıştır.

Coverage metriği	chr20	chr21
Genome territory	250,099 bp	166,038 bp
Mean coverage	71.55×	18.43×
Median coverage	73×	2×
PCT_EXC_MAPQ	0.58%	88.68%
≥1× coverage	99.97%	57.91%
≥10× coverage	99.57%	32.55%
≥20× coverage	99.27%	22.70%
≥30× coverage	98.48%	16.20%
≥50× coverage	93.97%	9.48%

Kromozom 20'de mean coverage 71.55× ve median coverage 73× olarak belirlenmiştir. Bölgenin %98.48'i en az 30× yüksek kaliteli coverage'a sahipken, MAPQ nedeniyle dışlanan

veri oranı yalnızca %0.58'dir. Ayrıca 250,099 bp'lik bölgede yalnızca 70 baz 0× coverage göstermiştir.

Kromozom 21'de ise mean coverage 18.43× olmasına rağmen median coverage yalnızca 2×'dir. Potansiyel coverage'ın %88.68'i düşük mapping quality nedeniyle dışlanmıştır. Bölgenin yalnızca %16.20'si en az 30× coverage'a sahiptir ve 166,038 bp'lik değerlendirilebilir bölgenin 69,888 bazı 0× yüksek kaliteli coverage göstermektedir.




Figure 3. High-quality coverage depth comparison between chr20 and chr21. Chr20 shows mean/median coverage of 71.5×/73×, whereas chr21 shows 18.4×/2×.




Figure 4. Fraction of analyzed bases meeting selected high-quality coverage thresholds. Chr20 retains near-complete breadth through ≥30×, while chr21 loses substantial usable coverage after MAPQ/base-quality filtering.

Bu sonuç, ham mapped read sayısının tek başına veri kalitesi için yeterli bir ölçüt olmadığını açık biçimde göstermektedir. Kromozom 21’de kromozom 20’ye göre daha fazla mapped read bulunmasına rağmen, bu reads’in çok büyük bölümü düşük MAPQ nedeniyle güvenilir coverage’a katkıda bulunamamaktadır.

5. Tartışma

Bu çalışmada incelenen BAM dosyasında genel mapping oranı yaklaşık %89.2 olarak bulunmuştur. Bu değer tek başına değerlendirildiğinde hizalamanın büyük bölümünün başarılı olduğu düşünülebilir. Ancak MAPQ dağılımı incelendiğinde mapped reads’in yaklaşık yarısının MAPQ=0 olduğu görülmüştür. Dolayısıyla yalnızca mapped/unmapped oranına bakılması, veri setinin gerçek hizalama kalitesini olduğundan daha iyi gösterebilir.

MAPQ=0 reads’in genomik dağılımının incelenmesi bu anomalinin kaynağını anlamak açısından kritik olmuştur. Düşük mapping quality genom boyunca rastgele dağılmak yerine neredeyse tamamen kromozom 21’deki dar bir test bölgesinde yoğunlaşmıştır. Kromozom 20’deki karşılaştırmalı bölgede ise çok yüksek MAPQ ve oldukça homojen coverage gözlenmiştir.

Bu sonuç, yüksek MAPQ=0 oranının genel sequencing kalitesindeki bir bozukluktan ziyade bölgesel mapping ambiguity ile uyumlu olduğunu göstermektedir. Böyle bölgelerde kısa reads referans genom üzerinde birden fazla benzer konuma hizalanabilir. Bir aligner read’i bir konuma yerleştirse bile bu atamaya duyulan güven düşük olabilir ve MAPQ=0 değeri oluşabilir.

Coverage analizi bu yorumu bağımsız biçimde desteklemiştir. Chr21 bölgesinde ham mapped read sayısı yüksek olmasına rağmen, Picard’ın MAPQ $\geq$ 20 filtresinden sonra kullanılabilir coverage ciddi şekilde azalmıştır. Potansiyel coverage’ın yaklaşık %88.7’si mapping-quality filtresi nedeniyle dışlanmış ve median coverage yalnızca 2 $\times$ kalmıştır. Buna karşılık chr20’de MAPQ nedeniyle dışlama yalnızca %0.58 olmuş ve median coverage 73 $\times$ olarak hesaplanmıştır.

Bu sonuç aynı zamanda “yüksek coverage her zaman iyi coverage değildir” ilkesini göstermektedir. Eğer bir bölgede çok sayıda read bulunmasına rağmen bu reads’in genomik konumu güvenilir değilse, ham depth değeri varyant çağırma açısından yanıltıcı olabilir. Variant callers genellikle düşük MAPQ reads’i filtrelediği veya düşük ağırlık verdiği için gerçek kullanılabilir coverage çok daha düşük olabilir.

Paired-end library özellikleri ise genel olarak daha sağlıklı görünmektedir. Read uzunluğu sabit olarak 101 bp bulunmuş, insert-size dağılımı yaklaşık 400 bp çevresinde yoğunlaşmış ve beklenen FR orientation gözlenmiştir. Mean, median ve mode insert-size değerlerinin birbirine yakın olması library fragment size dağılımının ana gövdesinin tutarlı olduğunu göstermektedir. Strand balance'ın yaklaşık 0.50 olması da belirgin strand bias bulunmadığını desteklemektedir.

Duplicate nedeniyle coverage'dan çıkarılan veri oranı birleştirilmiş analizde yaklaşık %5.3 düzeyindedir ve düşük base-quality nedeniyle oluşan kayıp %1'in altındadır. Dolayısıyla bu veri setindeki temel sınırlayıcı faktör PCR duplication veya düşük baz kalitesi değil, belirli bir bölgede yoğunlaşan düşük mapping confidence'dır.

Analizin önemli bir sınırlılığı, kullanılan BAM dosyasının tam genom verisi olmamasıdır. Dosya yalnızca kromozom 20 ve 21'in yaklaşık 10 Mb civarındaki dar bölgelerini içeren bir test subset'idir. Bu nedenle elde edilen mapping ve coverage istatistikleri NA12878 örneğinin tüm genom sequencing performansını temsil etmez. Özellikle chr21 test bölgesinin mapping açısından sıra dışı özellikleri, tüm veri setinin genel MAPQ dağılımını ciddi biçimde etkilemektedir.

Ayrıca CollectAlignmentSummaryMetrics sırasında referans genom verilmeden oluşturulan mismatch/error alanları güvenilir biçimde yorumlanmamıştır. Bu nedenle raporda esas kalite değerlendirmesi mapping rate, MAPQ, paired-end consistency, insert size ve reference-supported coverage ölçütlerine dayandırılmıştır.

6. Sonuç

Bu çalışmada CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam dosyasının post-alignment kalite kontrolü gerçekleştirilmiştir.

Toplam 654,610 read'ın %89.2'sinin referansa hizalandığı görülmüştür. Paired-end yapı genel olarak tutarlı bulunmuş, reads'in %96.45'i pair halinde hizalanmış, ortalama read uzunluğu 101 bp ve median insert size 396 bp olarak belirlenmiştir.

MAPQ analizi ise mapped reads'in yaklaşık %49.3'ünün MAPQ=0 olduğunu göstermiştir. Bölgesel analiz sonucunda bu düşük güvenli hizalanmaların yaklaşık tamamının chr21'deki sınırlı test bölgesinde yoğunlaştığı belirlenmiştir.

Coverage analizi bu sonucu doğrulamıştır. Chr20 bölgesinde median high-quality coverage $73\times$ ve $\geq 30\times$ coverage oranı %98.5 iken, chr21 bölgesinde median coverage yalnızca $2\times$ ve $\geq 30\times$ coverage oranı %16.2 olarak bulunmuştur. Chr21’de potansiyel coverage’ın yaklaşık %88.7’si düşük MAPQ nedeniyle dışlanmıştır.

Sonuç olarak veri setinin genel sequencing ve paired-end library özelliklerinde belirgin bir global kalite problemi saptanmamış; temel sınırlılığın chr21’deki belirli bir bölgede görülen ciddi mapping ambiguity olduğu değerlendirilmiştir. Bu çalışma, yalnızca toplam mapping oranının değil, MAPQ dağılımı ve bölgesel high-quality coverage değerlerinin birlikte değerlendirilmesinin varyant çağırma öncesi kalite kontrol açısından gerekli olduğunu göstermektedir.

7. Kaynaklar

- [1] SAM/BAM Format Specification, SAM/BAM Format Specification Working Group, SAMv1.
- [2] Broad Institute, Picard Tools Documentation: CollectAlignmentSummaryMetrics, CollectInsertSizeMetrics ve CollectWgsMetrics.
- [3] Broad Institute GATK test resources, CEUTrio.HiSeq.WGS.b37.NA12878.20.21.bam.
- [4] Li H. ve Durbin R. Fast and accurate short read alignment with Burrows-Wheeler transform. Bioinformatics. BWA alignment algorithm.
- [5] Genome Analysis Toolkit (GATK), GRCh37/b37 reference resources and sequence-processing documentation.